

Similitud semántica en la recuperación de información geográfica para la toma de decisiones

Semantic similarity in geographic information retrieval for decision making

Neili Machado/Carlos Balmaseda
Departamento de Informática
Universidad Agraria de la Habana
Mayabeque, Cuba
[neili,cbalma}@unah.edu.cu](mailto:{neili,cbalma}@unah.edu.cu)

Andres Montoyo
Director Escuela Politécnica Superior
Universidad de Alicante
Alicante, España
montoyo@dlsi.ua.es

Resumen—Las personas utilizan la similitud para almacenar y recuperar información, también para el aprendizaje y la formación de conceptos. La similitud juega un papel fundamental en muchas aplicaciones como sistemas de toma de decisiones, minería de datos o reconocimiento de patrones. Lo mismo ocurre con la similitud espacial en los procesos de recuperación e integración de información espacial. En el presente trabajo se propone una metodología basada en el procesamiento semántico de información geoespacial. Se compone de cinco etapas: conceptualización, síntesis, procesamiento de la solicitud, recuperación y ordenamiento. Utiliza una ontología de la Nueva Clasificación Genética de los Suelos de Cuba y aplica el algoritmo de Cálculo de la Distancia Conceptual (DIS-C) combinada con una implementación del modelo TDD (Topología-Dirección-Distancia) para recuperar y apoyar al usuario en la selección de las escenas espaciales. Como caso de estudio se considera el municipio de San José de Las Lajas ubicado en la provincia de Mayabeque en la región occidental de Cuba. (Resumen)

Palabras Claves—medidas de similitud semántica; objetos geográficos; ontologías (palabras claves)

Abstract —People use the similarity to store and retrieve information comparing new situations with similar experiences occurred in the past also for learning and concept formation. While equality comparison between two objects can be calculated by computers quickly and accurately similarity is a complex problem to calculate. Even still difficult to determine similarity plays a fundamental role in many applications such as decision-making systems, data mining and pattern recognition. The same applies to the spatial similarity in the processes of recovery and integration of spatial information. In this paper a methodology based on the semantic processing of geospatial information is proposed. It consists of five stages: conceptualization, synthesis, application processing, retrieval and management. It uses ontology of New Genetic Soil Classification of Cuba and applying the measure of semantic similarity Conceptual Distance (DIS-C) combined with an implementation model TDD (Topology-Direction-Distance) to restore and support the user in the selection of spatial scenes. As a case study is considered the town of San Jose de Las Lajas located in the province of Mayabeque in western Cuba.

Keywords - semantic similarity measures, geographic objects, ontology.

I. INTRODUCTION

En los últimos años las medidas de similitud han sido utilizadas para la recuperación de información y por lo tanto en el dominio de la información espacial. Inicialmente se aplicaban en los motores de búsquedas y paulatinamente han pasado a ser más visibles integrándose en las interfaces de usuarios.

La similitud constituye un elemento básico para la inferencia analógica [1]. Las personas utilizan la similitud para almacenar y recuperar información comparando nuevas situaciones con experiencias similares ocurridas en el pasado también para el aprendizaje y la formación de conceptos [2]. Mientras que la comparación de igualdad entre dos objetos puede ser calculada por las computadoras de forma rápida y precisa la similitud es un problema complejo de calcular. Aun siendo difícil de determinar la similitud juega un papel fundamental en muchas aplicaciones como sistemas de toma de decisiones, minería de datos o reconocimiento de patrones. Lo mismo ocurre con la similitud espacial en los procesos de recuperación e integración de información espacial [3].

A diferencia de la similitud entre documentos, la cual trabaja con la comparación de las palabras, la similitud espacial depende de diferentes elementos como las relaciones y la distribución espacial, los atributos geométricos y temáticos y las relaciones semánticas [4]. Al determinar la similitud semántica entre conceptos geoespaciales es importante tener en cuenta sus relaciones espaciales en el proceso de cálculo.

La mayoría de las representaciones semánticas de los conceptos espaciales se basan en características o descriptores de la información que tienen un carácter ambiguo en la explicación de lo que representan estas características. Gran parte de los modelos más empleados para determinar la similitud semántica se aplican a dominios generales, no se enfocan en las propiedades particulares de los conceptos en el dominio espacial [5] y utilizan una ontología compartida que relaciona los conceptos semánticamente. Los modelos basados

en las relaciones semánticas generalmente incluyen dos tipos de relaciones: la sinonimia (equivalencia) y la hiponimia (es-un). En el dominio espacial es importante tener en cuenta la relación de meronimia (es parte de) que proporciona una mejor representación de las interrelaciones entre los conceptos espaciales.

En el presente trabajo se propone una metodología basada en el procesamiento semántico de información geoespacial. Se compone de cinco etapas: conceptualización, síntesis, procesamiento de la solicitud, recuperación y ordenamiento. Utiliza una ontología de la Nueva Clasificación Genética de los Suelos de Cuba y calcula la similitud semántica a través del algoritmo de Distancia Conceptual (DISC) combinada con una implementación del modelo Topología-Dirección-Distancia (TDD) para recuperar y apoyar al usuario en la selección de las escenas espaciales. Como caso de estudio se considera el municipio de San José de las Lajas ubicado en la provincia de Mayabeque en la región occidental de Cuba.

Este documento se organiza en cinco secciones principales. En la sección 2 se presenta un resumen de los trabajos más relevantes relacionados con las medidas de similitud aplicadas a datos geoespaciales. En la sección 3 se presenta la metodología propuesta. Luego en la sección 4 se comentan los principales resultados de una primera implementación y experimentación del sistema. Finalmente se exponen en la sección 5 las conclusiones y líneas futuras de investigación.

II. TRABAJOS RELACIONADOS

En la actualidad muchas investigaciones están encaminadas a encontrar la manera de codificar formalmente el contexto y las relaciones geográficas. Un tipo de relación de este ámbito son las que existen entre datos geoespaciales, el conocimiento entorno a estos y su interrelación.

La comparación de los conceptos que describen el significado de los datos en fuentes de información distribuidas es un enfoque que apunta a convertirse en una solución eficiente para el procesamiento de los datos geográficos desde el punto de vista semántico [6].

El estudio de los sistemas de recuperación de información en el campo de las Geociencias, concentra sus esfuerzos en estudiar otras formas de representar el conocimiento, modificar la manera en que se almacenan y organizan los datos, así como la búsqueda de mecanismos que extraigan información controlando su precisión, para que correspondan de manera exacta o similar las respuestas arrojadas con las consultas que realizan los usuarios.

La similitud semántica es fundamental para el procesamiento semántico de datos geoespaciales. Establece el grado de interoperabilidad semántica entre los datos o los diferentes Sistemas de Información Geográfica (SIG) y constituyen las bases para la recuperación y la integración de información semántica [7].

En los SIG la similitud es particularmente importante debido a la dificultad para obtener representaciones satisfactorias de los fenómenos geográficos y a la variedad de formalizaciones que existen de las propiedades espaciales tales como su forma, localización y relaciones espaciales [8].

En su propuesta [4] proponen una medida de similitud que integra cuatro modelos, el modelo geométrico, el modelo de características, el modelo de transformación y el modelo de alineación estructurada para calcular las igualdades y las diferencias entre escenas espaciales y a nivel de capa. Aplica el orden de prioridad topología, dirección, distancia y se disminuyen los costos de transformación. Ambas características son implementadas a través de la aplicación de los pesos.

Un enfoque de integración de las relaciones espaciales y mediciones de similitud semántica entre diferentes conceptos geoespaciales considerando que las relaciones espaciales son partes fundamentales de la descripción semántica de los geodatos se presentan en [9]. Se seleccionan un conjunto de relaciones espaciales formalizadas en lenguaje natural según el modelo computacional de Shariff et al. El trabajo está enfocado en la medición de las distancias semánticas en el nivel conceptual. Un ejemplo de integración de información geográfica a nivel de sistema son los SIG gobernado por ontologías (SIGGO) que actúan como un sistema integrador independientemente del modelo [8].

El concepto de ontología ha atraído una atención creciente en la comunidad de las ciencias de la información debido a su capacidad para lograr una representación del conocimiento compartido. Las ontologías tienen una gran importancia en la creación y uso de las normas de intercambio de datos, así como en la solución de problemas derivados de la heterogeneidad y poca interoperabilidad de los datos geográficos. Las ontologías pueden ser usadas como una alternativa para representar los datos y, de forma explícita, el conocimiento acerca de ellos.

Para el procesamiento semántico del conocimiento de los datos geoespaciales almacenados en las ontologías es fundamental el cálculo de la similitud semántica, la cual es esencial en el procesamiento de las consultas de datos de los usuarios y es la base para la recuperación e integración de información semántica [2].

III. METODOLOGÍA PROPUESTA

La metodología propuesta se basa en un procesamiento semántico que permite localizar un determinado tipo de suelo con determinadas características. Además de devolver la ubicación del suelo recupera imágenes de estos suelos permitiéndole al usuario una visualización de las características y propiedades de los mismos.

Aplica medidas de similitud semánticas y emplea un vocabulario estructurado que incluye la información geográfica referida al Recurso Suelo pero los resultados, desde el punto de vista metodológico, pueden ser válidos para cualquier otro tipo de Información Geográfica (IG). El área seleccionada para el estudio pertenece al municipio de San José de las Lajas ubicado en la Provincia Mayabeque en la región occidental de Cuba. Los suelos son clasificados de acuerdo con su estructura y composición. El método está compuesto por cinco etapas: Conceptualización, Síntesis, Procesamiento de la solicitud, Recuperación y Ordenamiento.

A. Marco de trabajo

La Fig. 1 muestra cómo se lleva a cabo el proceso de gestión de los recursos para localizar un suelo con determinadas características realizando un procesamiento semántico para esto. Inicialmente se realiza la **Conceptualización** del dominio de trabajo describiéndolo a través de una jerarquía de objetos con sus relaciones y características.

El uso de las ontologías, como mecanismos para representar conocimiento de un dominio concreto, puede ayudar a un sistema de gestión a focalizar las consultas de los usuarios y a llegar a sitios donde la comparación sintáctica entre cadenas de caracteres no es suficiente.

Estas estructuras proporcionan la vía para representar conocimiento. Son más que una taxonomía, en ellas los significados de los términos no son ambiguos, lo que los hace semánticamente independientes del usuario y del contexto. Identifican clases de objetos, sus relaciones y las jerarquías de conceptos dentro de un dominio específico.

El propósito de las ontologías no es servir de vocabulario o taxonomía sino el compartimiento y reusabilidad del conocimiento entre aplicaciones. En este trabajo se presenta una ontología que describe las características de los suelos de la Provincia de Mayabeque en la región occidental de Cuba siguiendo la Nueva Versión de Clasificación Genética de los Suelos (ver Fig. 2).

En la **Síntesis** se instancia la ontología con los datos almacenados en PostGis para establecer una relación de las imágenes que muestran los suelos según la clasificación con los mapas y los conceptos de la ontología. La integración de datos espaciales en ontologías debe realizarse mediante un proceso previo de anotación de los datos. La forma más simple de integrar datos espaciales a ontologías es almacenando completamente el dato en la ontología, es decir, los bytes que representan al dato espacial estarán embebidos en la estructura ontológica en algún apartado previsto para ello. Pero no basta con embeber el dato íntegramente en la ontología sino que es necesario hacer una correspondencia entre los objetos geográficos presentes en el dato y los conceptos vinculados con ellos.



FIGURA 2. FRAGMENTO DE LA ONTOLOGÍA

Dentro del **Módulo de Procesamiento** de la solicitud del usuario se enriquece la consulta del usuario convirtiendo la consulta sintáctica en una representación semántica equivalente, a partir de las relaciones entre los conceptos de una ontología. El primer paso que sufre la cadena de búsqueda introducida por el usuario básicamente consiste en simplificar y normalizar las palabras de la consulta, eliminando palabras no relevantes (stop words), singularizando las palabras, etc. Para este paso se utiliza el analizador morfológico Freeling de la Universidad de Barcelona.

El segundo paso tiene por objetivo reconocer los objetos y los operadores espaciales que los relacionan (ver Fig. 3). Finalmente, se activan en la ontología los conceptos subyacentes. Para esto cada concepto en la ontología cuenta con un conjunto de sinónimos, cada uno de los términos relevantes de la consulta se localizan en la ontología, utilizando el conjunto de sinónimos. Posteriormente se activan los términos similares a los términos de búsqueda. Para identificar los conceptos similares en la ontología se utiliza el algoritmo de DIS-C desarrollado por el CIC-IPN en México.

El algoritmo DIS-C funciona con todo tipo de ontologías porque no depende de las relaciones taxonómicas. La idea principal es determinar el valor de distancia conceptual a cada uno de los tipos de relaciones en la ontología. Esto se logra al convertir esta última en un grafo dirigido y ponderado en el que cada concepto se convierte en un nodo y cada relación se convierte en un par de aristas. Esto es aplicable de manera directa a las relaciones binarias, pero también es posible aplicarlo a relaciones n-arias. Una vez que se tiene el grafo, se aplican técnicas de teoría de grafos. El paso natural consiste en calcular las distancias mínimas, con lo que se puede encontrar la distancia entre conceptos que no se encuentran directamente relacionados.

Posteriormente con todos los conceptos obtenidos (iguales y similares) se ejecuta el **Módulo de Recuperación** el cual se inicia buscando los conceptos iguales o semejantes y las relaciones que representan los objetos. Cuando se encuentra una coincidencia se extraen las relaciones asociadas y sus clases o instancias respectivas. Pueden ocurrir 4 tipos de coincidencias: completa, parcial, atómica o nula; depende del umbral de similitud aunque es muy poco probable que haya coincidencia nula. Una vez identificados los objetos idénticos o similares en la ontología se ubican según las escenas espaciales




Figura 1. Arquitectura del modelo de gestión.

FIGURA 1. ESQUEMA DE LA METODOLOGÍA




FIGURA 3. PROCESAMIENTO DE LA SOLICITUD



FIGURA 4. PLATAFORMA DE EXPERIMENTACIÓN

a las que pertenecen. Se realiza la comparación de las escenas espaciales teniendo en cuenta la similitud espacial según el Modelo TDD [4]. Las imágenes recuperadas están relacionadas semánticamente con los conceptos de la base de conocimientos y en los mapas se detalla su ubicación espacial. Al usuario se le muestran las imágenes del suelo que buscaba, o alguno con características similares, con su respectiva ubicación en el mapa. Si desea ver la imagen ampliada, la selecciona y además se le brinda la descripción de la imagen.

Sobre este listado de las imágenes ordenadas por la relevancia de los términos se aplica el **Módulo de Filtrado y Ordenamiento**. Cuando una imagen es adicionada a un repositorio sus características son extraídas y relacionadas con los conceptos de la ontología. Una vez que un usuario utiliza una imagen, estas características son almacenadas como preferencias del usuario y a partir de estas el usuario puede solicitar una nueva búsqueda, mostrándose finalmente las imágenes relacionadas con las preferencias y otras que están relacionadas a estas, pero que no están dentro de las preferencias del usuario. Finalmente, el sistema muestra listas ordenadas de imágenes con el mapa donde se encuentran localizados los suelos que cumplen los requerimientos del usuario. Además de mostrarle otros conceptos similares que pueden resultar de interés.

El usuario del sistema, por otra parte, tendrá un perfil con sus datos y preferencias almacenadas, obtenidas como resultado de la búsqueda de imágenes de suelos, que se irán almacenando según las búsquedas más frecuentes del usuario. Si ya ha realizado varias búsquedas y tiene preferencias en su perfil, entonces podrá hacer una búsqueda personalizada, donde al seleccionar las imágenes relacionadas semánticamente con esta se le mostrarán otras relacionadas con la preferencia que no estén en el perfil.

IV. RESULTADOS

Se desarrolló una plataforma de experimentación, la cual se nombró como SI Geopedia y su objetivo fundamental es la implementación y prueba de los métodos desarrollados. Esta plataforma presenta las funcionalidades básicas existentes en los SIG convencionales accesibles a través de la barra de herramientas, véase Fig. 4, estas son:

- Carga y visualización de capas de datos.
- Interacción con el mapa (Paneo, Zoom, Restablecer).
- Consulta a los datos.

La plataforma también posee un visor de mapas en el cual se visualizan los datos cargados a través de su componente espacial (ver Fig. 5).

El sistema de gestión resultante permite realizar búsquedas de información de los diferentes tipos de suelos. Al seleccionar la opción buscar, por ejemplo, si se lanza una búsqueda de determinado tipo de suelo "tipo ferralítico rojo", se recupera un mapa de la región en el cual se visualiza la localización de este tipo de suelo (ver Fig. 5), además, se mostrarán todas las imágenes relacionadas con la solicitud y si el usuario lo desea al dar clic en alguna de estas imágenes esta se mostrará con una vista más amplia, mostrando la descripción de la misma y los conceptos de la ontología que tienen relación semántica con la misma.

En la Tabla I se presentan ejemplo de como el sistema una vez que procesa la solicitud del usuario determina a través de cual operador, el cual identifica a la relación espacial, se deben relacionar los objetos que se están buscando.

Además se logra un ahorro de tiempo en la realización de los análisis espaciales. Esto es debido a que se suprimen una serie de pasos que conllevan a un gasto de tiempo y en los cuales es posible la comisión de errores, tales como:

- La búsqueda de las capas de datos con las que se desea trabajar ya que estas se encuentran conceptualizadas en la ontología generada.
- La creación de una consulta en lenguaje SQL ya que el usuario navega libremente por dicha ontología, además podrían implementarse métodos de búsqueda basados en lenguaje natural.

Ejemplos de consultas que el sistema automáticamente no podría dar respuestas utilizando los métodos convencionales serían las siguientes:

¿Qué ríos se encuentran el municipio de San José?

¿Cuáles son las regiones de suelos que rodean la presa Mampostón?

Este tipo de consulta no puede ser obtenido a través de lenguaje *SQL* ya que tanto en la base de datos como en el archivo *ShapeFile* no existe ninguna tabla nombrada con los términos utilizados en la consulta. Por tanto, a través del uso de la ontología el sistema puede entender fácilmente lo que se desea recuperar.




FIGURA 5. VISOR DE MAPAS

Además las recuperaciones fueron realizadas sin la necesidad de la construcción de una consulta en lenguaje SQL por lo que es posible expandir su utilización a usuarios no expertos.

En la tabla II se presentan los resultados comparativos en cuanto a eficiencia de los métodos propuesto. Estos resultados ponen de manifiesto como las relaciones existentes entre los objetos, en este caso las relaciones topológicas, resultan útiles en tareas como la determinación automática de la zonificación de los suelos. Otro aspecto a destacar es que las tareas de recuperación de datos utilizando la estructura y los métodos propuestos resultan ser más simples y rápidas que los métodos convencionales para el caso de usuarios no expertos en aplicaciones SIG, ya que posibilita que estos puedan navegar por la ontología y realizar distintos tipos de análisis a partir de las recuperaciones sin la necesidad de conocer las herramientas de análisis de los SIG. Los resultados demuestran que la recuperación de la información mediante el método propuesto aumenta la calidad de los análisis pues reduce los posibles errores en las operaciones que deben realizar, por ejemplo, al crear la consulta.

TABLA I TÉRMINOS O PALABRAS ASOCIADAS A RELACIONES ESPACIALES

Ejemplo de uso de la relación espacial	Relación espacial	Operación o relación espacial asociada
Jaruco está «junto» a Santa Cruz	Junto	Conecta
El río Mayabeque «intersecta» el municipio Guines	Intersecta	Intersección
El río Jaruco «cruza» el municipio Jaruco	Cruza	Intersección

TABLA II RESULTADOS DE LAS COMPARACIONES ENTRE TIEMPOS DE LA REALIZACIÓN DE LAS OPERACIONES DE BÚSQUEDA Y ANÁLISIS DE LA INFORMACIÓN ESPACIAL UTILIZANDO EL MÉTODO PROPUESTO Y MÉTODOS DE RECUPERACIÓN BASADA EN EL LENGUAJE SQL.

Pasos Metodológicos	Selección de regiones por tipo de suelo
Operaciones en el SIG	- Selección manual de la capa. - Conformación manual de la Sentencia SQL. - Selección automática de los objetos
Tiempo (min)	3.0
Operación en la plataforma	- Selección manual del criterio en la ontología. - Selección automática de las instancias
Tiempo (min)	0.5

Estos resultados muestran que el uso de la ontología como una capa intermedia entre el sistema de recuperación y la base de datos espacial permite el manejo de los objetos a través de su representación conceptual (abstracción). Dando la posibilidad de que el sistema disponga de herramientas para el procesamiento semántico de los datos geoespaciales. Esto permite que los diferentes tipos de análisis realizados sobre los estos tipos de datos puedan ser realizados tanto por especialistas como por usuarios no expertos en el uso de SIG.

V. CONCLUSIONES

En el presente trabajo se ha propuesto una metodología para optimizar la gestión semántica de información geoespacial aplicando medidas de similitud en el proceso de recuperación. La aplicación de la medida de similitud semántica hace que se evite retornar resultados vacíos, pero hay que ser cuidadosos con los resultados que pueden estar completamente alejados de lo que busca el usuario.

Al usar el análisis semántico es posible aproximarse a una forma de procesamiento inteligente, el cual no obedece exclusivamente a una coincidencia sintáctica pero sin olvidar las ventajas del enfoque geoespacial clásico.

La implementación del algoritmo DIS-C automatiza el análisis de distancia conceptual sin la necesidad de establecer pesos a cada relación basada en la percepción de algún individuo o individuos, siendo aplicable a cualquier tipo de ontología.

Con este trabajo se contribuye a disminuir la carencia de sistemas que integren aspectos semánticos conjuntamente con aspectos espaciales, de allí que el modelo de integración presentado en este trabajo, expone el análisis semántico como un excelente complemento mutuo para las técnicas tradicionales de análisis geoespacial.

En futuros trabajos se experimentará la arquitectura propuesta en grandes volúmenes de datos y se aplicarán nuevas medidas de similitud para identificar los objetos geográficos. Es necesario encontrar elementos que permitan una mayor vinculación entre la semántica formal y la información

necesaria para la visualización gráfica de la información geográfica.

REFERENCES

- [1] A. B. Markman, "Constraints on Analogical Inference.," *Cognitive Science.*, vol. 21(4), pp. 373–418, 1997.
- [2] A. Schwering, "Approaches to Semantic Similarity Measurement for Geo-Spatial Data - A Survey," *Transactions in GIS*, vol. 12(1), pp. 5–29, 2008.
- [3] M. A. Rodríguez and M. J. Egenhofer, "Determining semantic similarity among entity classes from different ontologies.," *IEEE Transactions on Knowledge and Data Engineering*, vol. 15(2), pp. 442–456, 2003.
- [4] B. Li and F. Fonseca, "TDD - A Comprehensive Model for Qualitative Spatial Similarity Assessment.," *Spatial Cognition and Computation*, vol. 6(1), pp. 31–62, 2006.
- [5] A. Schwering, "Semantic Similarity Measurement including Spatial Relations for Semantic Information Retrieval of Geo-Spatial Data," Münster, Deutschland, 2006.
- [6] R. Larín, "Nuevo tipo de ontología para la representación semántica de objetos geoespaciales," Centro de Aplicaciones de Tecnologías de Avanzada, La Habana, 2013.
- [7] K. Janowicz, M. Raubal, A. Schwering, and W. Kuhn, "Semantic Similarity Measurement and Geospatial Applications," Workshop on Semantic Similarity Measurement and Geospatial Applications, 2008.
- [8] F. Fonseca, "Ontology-Driven Geographic Information Systems," The University of Maine, The Graduate School, Maine, USA, 2001.
- [9] A. Schwering and M. Raubal, "Spatial Relations for Semantic Similarity Measurement," *Ordnance Survey*, 2005.